



Hochschule Karlsruhe  
Technik und Wirtschaft  
UNIVERSITY OF APPLIED SCIENCES



**inovex**

AI Labor - Sommersemester 2019

Computer Vision  
2. Termin

Robin Baumann, Stanislav Frolov

Karlsruhe, 29. März 2019

# Agenda für Heute

- Recap: Allgemeines
- Einführung TensorFlow
- Theorie zu MLPs
- Praktischer Teil: Bildklassifizierung



# Modus

- 14 Termine, jeweils 2 Blöcke
- 4 ECTS, 4 SWS
- Gruppenarbeit (3 Personen), max. 18 Personen
- Bewertung
  - Diskussion und Vorstellung der Lösungen + Fragen
    - am Ende oder während des nächsten Termins

# Modus

## Zulassungskriterien

1. Studierende von I und Modul ML vollständig bestanden
2. Studierende von I und Klausur ML bestanden
3. Studierende von anderen Fakultäten und Klausur ML bestanden (mit entsprechenden Python-Kenntnissen)
4. Auswahl im Losverfahren aus dem Rest der Welt (mit entsprechenden Methoden- und Python-Kenntnissen)

# Teamvorstellung

- Computer Vision (4 Termine)
  - Robin Baumann, Stanislav Frolov
- Natural Language Processing (5 Termine)
  - Anna Weisshaar, Tilman Wittl
- Reinforcement Learning (5 Termine)
  - Benedikt Hagen, Frederik Martin

# Computer Vision

1. Python, Jupyter, Grundlagen Computer Vision
2. TensorFlow, MLP, Bildklassifizierung
3. CNN, Objektklassifikation
4. AI auf Android Smartphone



# Einführung TensorFlow

# TensorFlow

## Allgemeines

- “open source machine learning framework for everyone”
- wird von Google entwickelt
- November 2015 veröffentlicht
- populärstes Framework für machine learning und künstliche neuronale Netze



# TensorFlow

- Fokus auf Training und Inferenz von tiefen Netzen
- “Large-Scale Machine Learning on Heterogeneous Distributed Systems”
- [Whitepapers](#)
- kann bspw. mit *pip* installiert werden

# TensorFlow

## Architektur

- flexible Architektur
- unterstützt CPUs, GPUs, TPUs, CUDA, Linux, Windows, macOS, Android, iOS

High-Level  
TensorFlow APIs

Estimators

Mid-Level  
TensorFlow APIs

Layers

Datasets

Metrics

Low-level  
TensorFlow APIs

Python

C++

Java

Go

TensorFlow  
Kernel

TensorFlow Distributed Execution Engine


# TensorFlow

## Grundlagen

- datenstromorientiert
- baut intern einen Datenflussgraph auf (data flow graph / computational graph)
- jeder Knoten steht für eine Berechnung, die auf den Daten ausgeführt wird (z.B. add, mult, sum, tanh, ...)
- Kanten repräsentieren den Datenfluss / Tensoren
- komplette Berechnung wird als gerichteter Graph repräsentiert

# TensorFlow

## Beispiel einfacher Graph



# TensorFlow

## Grundlagen

- **Programmablauf in Phasen**
  - Konstruktion des Graphen
  - Ausführung des Graphen mit Daten
- **Graph wird einmal statisch definiert, bevor das Modell ausgeführt wird (keine dynamische Anpassung des Graphen)**


# TensorFlow

## Tensor

- ein Tensor ist eine mathematische Funktion die eine Anzahl von Vektoren auf einen Wert abbildet
- Verallgemeinerung von Skalar, Vektor, Matrix
- multidimensionales Array/Matrix
- Tensoren fließen zwischen den Knoten des Graphen

# TensorFlow

## Beispiel komplexer Graph - GoogleNet



# TensorFlow

## Beispiel TensorFlow Operationen

Category	Examples
Element-wise mathematical operations	Add, Sub, Mul, Div, Exp, Log, Greater, Less, Equal, ...
Array operations	Concat, Slice, Split, Constant, Rank, Shape, Shuffle, ...
Matrix operations	MatMul, MatrixInverse, MatrixDeterminant, ...
Stateful operations	Variable, Assign, AssignAdd, ...
Neural-net building blocks	SoftMax, Sigmoid, ReLU, Convolution2D, MaxPool, ...
Checkpointing operations	Save, Restore
Queue and synchronization operations	Enqueue, Dequeue, MutexAcquire, MutexRelease, ...
Control flow operations	Merge, Switch, Enter, Leave, NextIteration



# TensorFlow

## Beispiel TensorFlow

```
import tensorflow as tf

b = tf.Variable(tf.zeros([100]))           # 100-d vector, init to zeroes
W = tf.Variable(tf.random_uniform([784,100],-1,1)) # 784x100 matrix w/rnd vals
x = tf.placeholder(name="x")              # Placeholder for input
relu = tf.nn.relu(tf.matmul(W, x) + b)    # Relu(Wx+b)
C = [...]                                 # Cost computed as a function
                                         # of Relu

s = tf.Session()
for step in xrange(0, 10):
    input = ...construct 100-D input array ... # Create 100-d vector for input
    result = s.run(C, feed_dict={x: input})    # Fetch cost, feeding x=input
    print step, result
```


# TensorFlow

## Beispiel TensorFlow

```
import tensorflow as tf

b = tf.Variable(tf.zeros([100]))
W = tf.Variable(tf.random_uniform([784,100],-1,1))
x = tf.placeholder(name="x")
relu = tf.nn.relu(tf.matmul(W, x) + b)
C = [...]

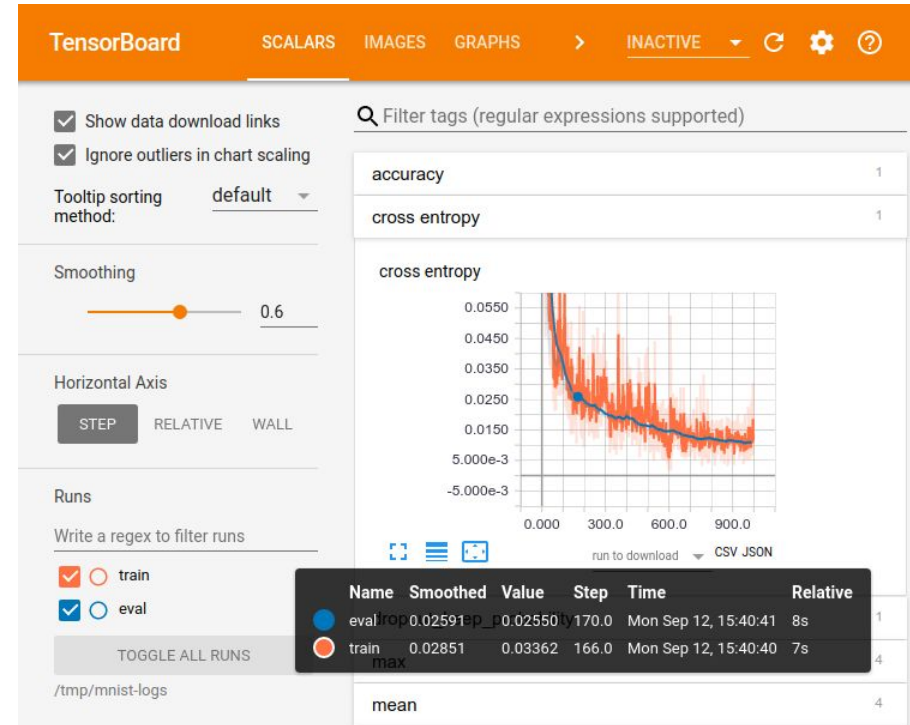
s = tf.Session()
for step in xrange(0, 10):
    input = ...construct 100-D input array ...
    result = s.run(C, feed_dict={x: input})
    print step, result
```




# TensorFlow

## Visualisierung mit TensorBoard

- Webapplikation, um den Graphen und den Verlauf des Trainings zu untersuchen
- `tensorboard`  
`--logdir=path/to/dir`
- `localhost:6006`



# Einführung MLP und MNIST



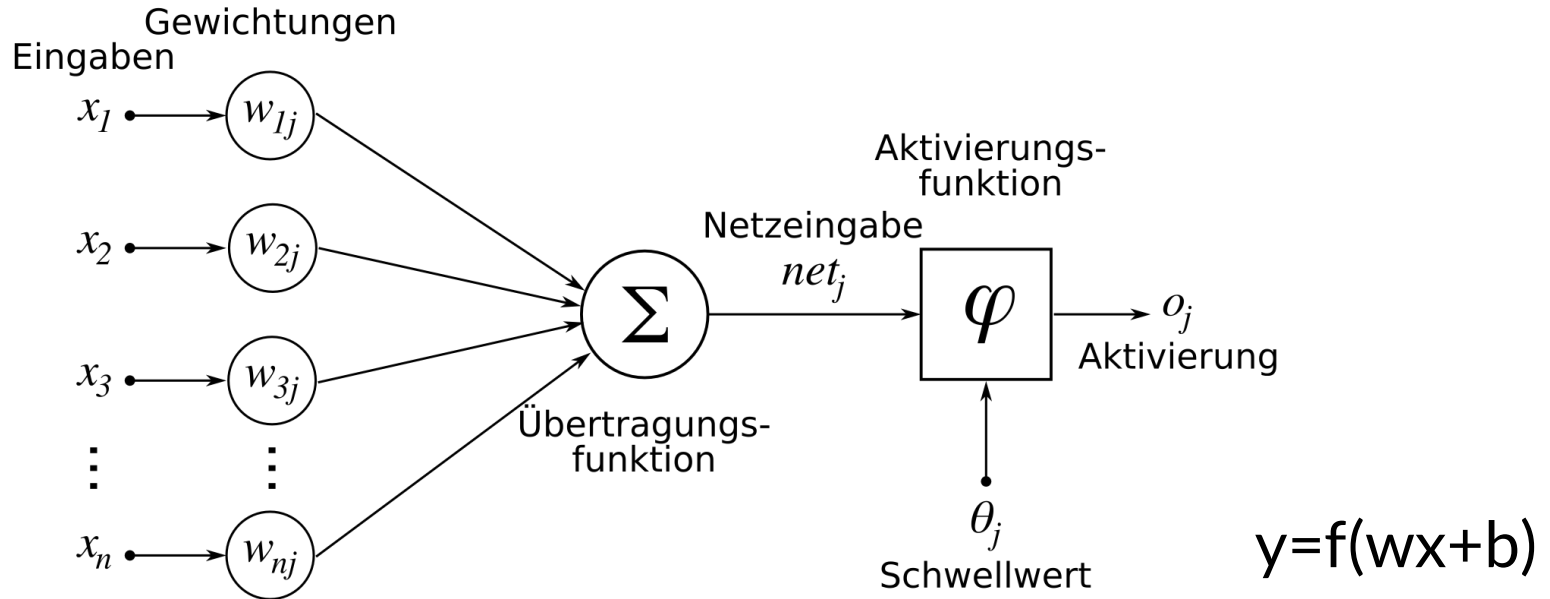
# Künstliche Neuronale Netze

## Überblick

- Anfänge in den 50ern
- Inspiriert von biologischen neuronalen Netzen
- Entwicklungen aufgrund mangelnder Ergebnisse, wenig Daten, unzureichender Rechenleistung eingestellt (schwer zu trainieren)
- Renaissance seit 2012 mit Deep Learning


# Ein künstliches Neuron

## Das Perzeptron



# Ein künstliches Neuron

## Multi-Layer Perceptron (MLP)




# Aktivierungsfunktionen

## Activation Functions


**Sigmoid**

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




**tanh**

$$\tanh(x)$$



**ReLU**

$$\max(0, x)$$



**Leaky ReLU**

$$\max(0.1x, x)$$




**Maxout**

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

**ELU**

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$





# Training

## Bildklassifizierung


- Input: Bilder und Labels
- Output: Klassen und Score
- Optimierungsproblem
  - minimiere Loss durch iterativen Prozess

# Training


## Bildklassifizierung

- Forward-Pass von einem Batch
- Berechne Fehler zwischen erzeugtem und gewünschtem Output
- Verändere die Gewichte, sodass der gleiche Forward-Pass einen kleineren Fehler erzeugen würde
- Wiederhole bis Konvergenzkriterium erreicht

# Dropout



(a) Standard Neural Net



(b) After applying dropout.

# Datensatz

## MNIST


- 60k Training
- 10k Test
- 28x28 Pixel

<http://yann.lecun.com/exdb/mnist/>





# Praktischer Teil



# Gruppenfindung

- Dreierteams bilden
- Name und Gruppe auf Zettel schreiben

# Setup

- Anmeldung am Rechner
- Ethernet auf `hskaopen` umstellen
- Wired Settings:
  - `testXYZ` entfernen und mit Studentenkürzel ersetzen
  - Passwort eingeben

# Setup

- Terminal öffnen

- `git clone`  
`https://github.com/hskaailabcv/source.git`
- `cd source`
- `docker-compose up`

- Jupyter: <http://localhost:8888>



# Feedback

- Google Forms

<https://forms.gle/Uy1LuRwcizcqiDK7>



# Vielen Dank

Robin Baumann

[rbaumann@inovex.de](mailto:rbaumann@inovex.de)

Stanislav Frolov

[sfrolov@inovex.de](mailto:sfrolov@inovex.de)

inovex GmbH

Ludwig-Erhard-Allee 6

76131 Karlsruhe



